Məlumat və əlamətlər

NumPy və pandas ilə iş — Data science dərsinin başlanğıcı. Nümunələr PyCharm-da işlədilir.

```
import numpy as np
import pandas as pd
age = np.array([18, 21, 19, 22])
```



Bu gün nə öyrənəcəyik?

Bu dərsdə aşağıdakı mövzuları ardıcıl şəkildə nəzərdən keçirəcəyik — hər biri bir sonrakısının əsasını qoyur.

01

NumPy massivi

Python siyahısından fərqi və effektivliyi

02

pandas Series və DataFrame

Sütun və cədvəl strukturu

03

Məlumatın oxunması

read_csv, read_excel, to_csv

04

DataFrame-ə baxış

head, tail, sample, info, describe

```
df = pd.read_csv("students.csv")
df.head()
df.info()
df.describe()
```

Siyahı, C++ massivi, ndarray

Python siyahısı

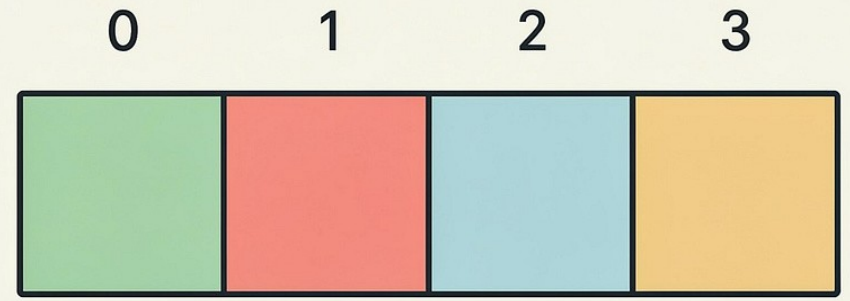
Obyektlərə göstəricilər saxlayır, ölçüsünü dəyişə bilir. Elementlərin tipi fərqli ola bilər — buna görə yaddaşda ardıcıl deyildir.

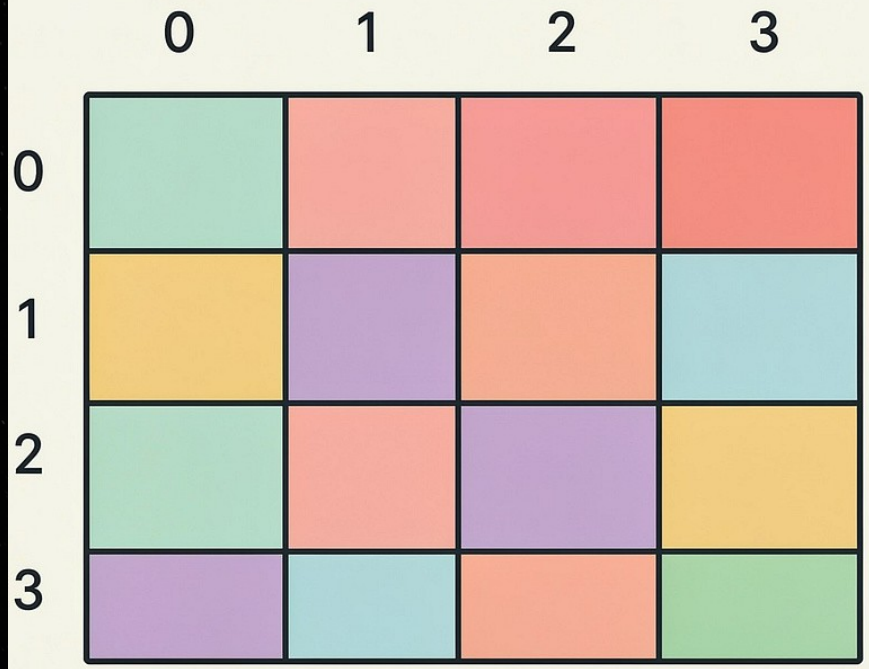
```
scores_list = [70, 85, 90]
scores_list.append("absent")
```

ndarray (C++ modeli)

Bir dtype, ardıcıl bufer. İndeks ünvanı: **başlanğıc + i × elementin ölçüsü**. Çoxölçülüdür, əməliyyat bütün buferə bir dəfədə tətbiq olunur.

```
scores = np.array([70, 85, 90],
dtype=np.int32)
scores[1]
scores.dtype
scores.nbytes
```





Əlamət ndarray-də durur

Əlamət eyni tipli ədədlər sütunudur. pandas sütunları bu massivlərin üzərində qurulur — buna görə hesablamalar Python dövrəsi olmadan sürətlə gedir.

Python siyahısı

Hər ədəd ayrıca Python obyektidir. Dövrə tələb olunur.

ndarray buferi

Bütün sütun bir buferdir. Toplama, orta, müqayisə C səviyyəsindədir.

```
age = np.array([18, 21, 19, 22])
score = np.array([70, 85, 90, 60])
age.mean()
age + 1
score[score >= 80]
```

Series bir sütundur

Series **indeksdən** və **qiymətlər massivindən** ibarətdir. Qiymətlər bir dtype-lı ndarray-dir. İndeks sətirin adıdır, mövqe isə 0, 1, 2 sırasıdır. Standart indeks RangeIndex-dir. **Bir əlamət = bir Series.**

.loc[]

Ada görə seçim

.iloc[]

Mövqeyə görə seçim

.to_numpy()

ndarray-ə çevirmə

```
age = pd.Series(
 [18, 21, 19, 22],
 index=["Aysel", "Murad",
 "Leyla", "Nigar"],
 name="age",
)
age.loc["Murad"]
age.iloc[1]
age.to_numpy()
```



DataFrame cədvəldir

Sətir müşahidədir, sütun əlamətdir. Hər sütun öz dtype-ı olan Series-dir. Sütunlar eyni indeks üzrə düzülür — DataFrame eyni indeksli bir neçə Series-dən ibarətdir.

```
df = pd.DataFrame({
    "name":  ["Aysel", "Murad", "Leyla", "Nigar"],
    "age":   [18, 21, 19, 22],
    "score": [70, 85, 90, 60],
})
df["score"]
df.dtypes
```

Data science-də işlənən cədvəl adətən DataFrame-dir. Onu başa düşmək demək olar ki, hər pandas əməliyyatını başa düşmək deməkdir.

Məlumatın oxunması və yazılması



read_csv

Mətn faylını DataFrame-ə çevirir. Sütunların tipini pandas avtomatik seçir.



read_excel

Excel vərəqini oxuyur. sheet_name ilə vərəq seçilir.



to_csv / to_excel

Cədvəli fayla yazır. index=False indeks sütununu çıxarmır.

```
df = pd.read_csv("students.csv")
df = pd.read_excel("students.xlsx", sheet_name=0)
df.to_csv("students_out.csv", index=False)
df.to_excel("students_out.xlsx", index=False)
```

head, tail, sample

Böyük faylda bütün cədvəli ekrana açmağa ehtiyac yoxdur. Bu üç metod cədvəlin kiçik hissəsinə sürətlə baxmağa imkan verir.

df.head(n)

İlk *n* sətiri göstərir. Susmaya görə **5**. Faylın başlanğıcını yoxlamaq üçün idealdır.

df.tail(n)

Son *n* sətiri göstərir. Faylın sonunda nə olduğunu yoxlamaq üçün istifadə edilir.

df.sample(n)

Təsadüfi *n* sətir götürür. random_state nəticəni sabitləşdirir.

```
df.head()
df.head(2)
df.tail(2)
df.sample(2, random_state=0)
```

info və describe

df.info()

Strukturu yoxlayır: sütun adı, dtype, dolu xanaların sayı və yaddaş istifadəsi. Hansı sütunun boş dəyər saxladığını ilk buradan görürsünüz.

df.describe()

Ədədi sütunlar üçün say, orta, standart kənarlaşma, minimum, kvartillər və maksimum verir. Qiymətlərin yayılmasını bir baxışda göstərir.

```
df.info()
df.describe()
```

Əlamətlərlə iş bu iki baxışdan başlayır — info quruluşu, describe isə qiymətlərin paylanmasını ortaya qoyur.

Dərs buradan gedir

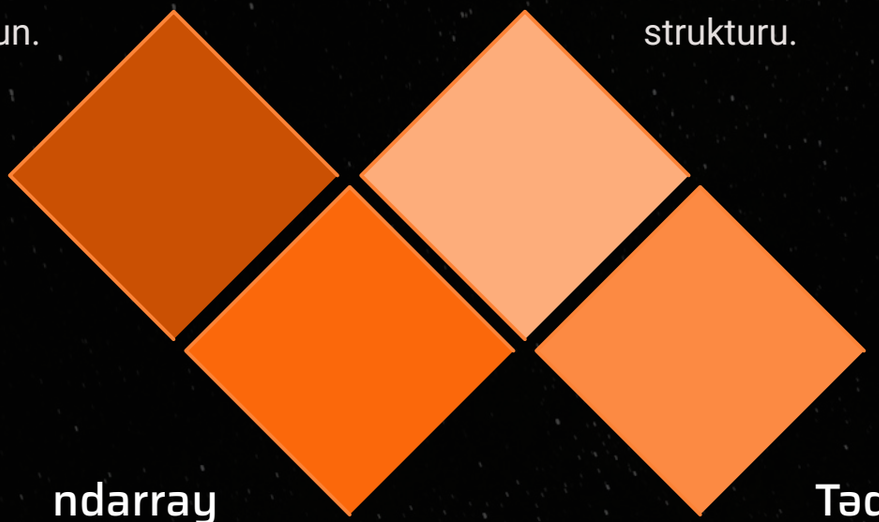
Bu dərsdə öyrəndiklərimizin qısa xülasəsi — növbəti addım statistika və paylanmalardır.

Series

Etiketlər və qiymətlərdən ibarət bir sütun.

DataFrame

Tam cədvəl məlumat strukturu.



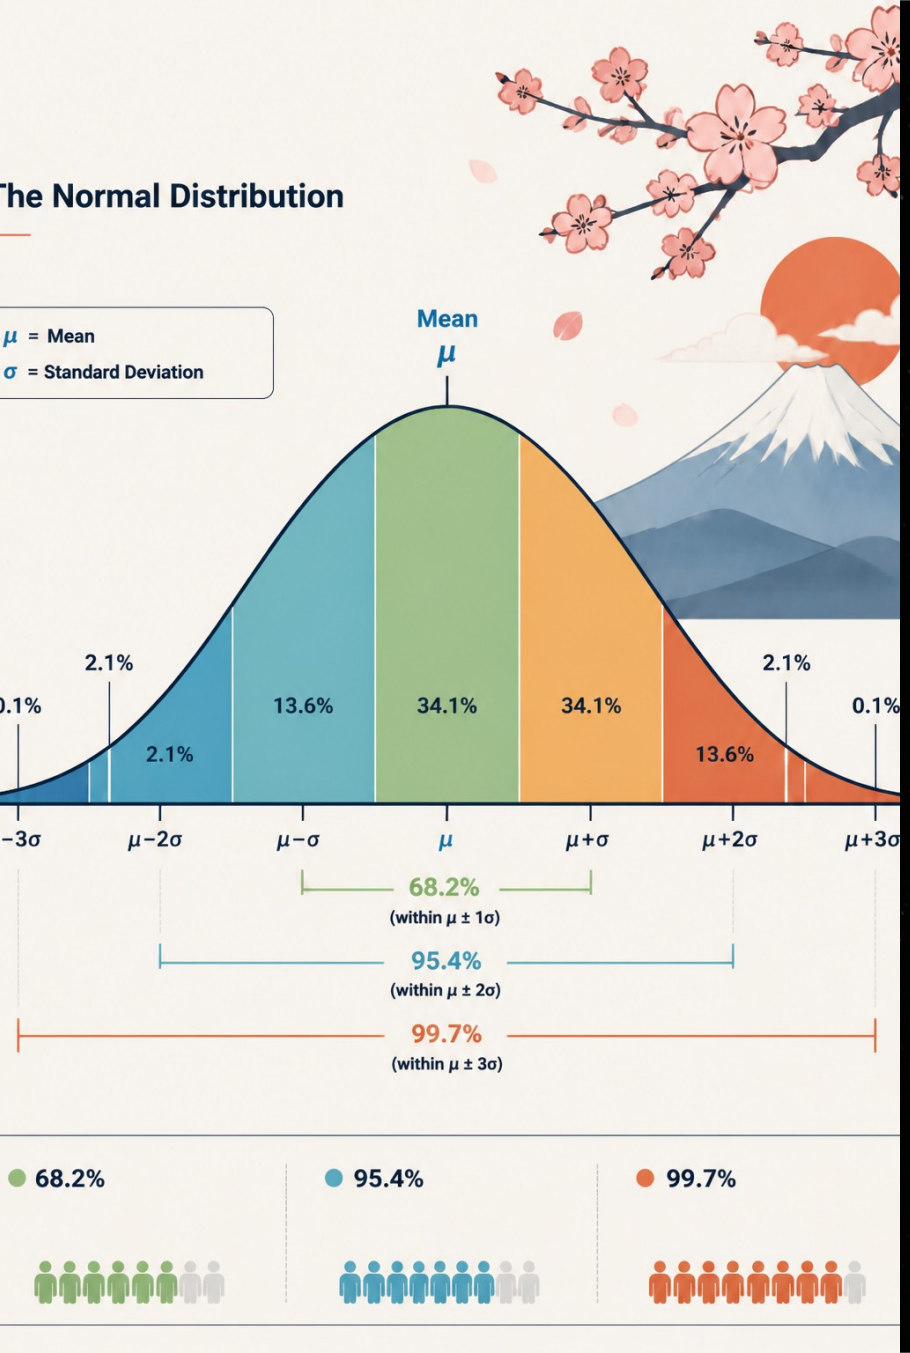
ndarray

Əlamətlərin massivlərdə saxlanması.

Tədqiqat

head, info, describe metodlarından istifadə edin.

```
df = pd.read_csv("students.csv")
df.head()
df.info()
df["score"].mean()
```



Əsas statistika

Təsadüfi kəmiyyət, orta göstəricilər və paylanma — data science-in riyazi özəyi.

```
score = np.array([70, 85, 90, 85, 60])
score.mean()
```

Təsadüfi kəmiyyət

Nədir?

Qiyməti təsadüfi nəticədən asılı olan kəmiyyətdir. Hər müşahidə onun bir qiymətidir. Eyni şəraitdə təkrar ölçüləndə qiymət dəyişə bilər.

Sütunla əlaqəsi

DataFrame-dəki hər sütun bir təsadüfi kəmiyyətin **seçməsidir** — yəni həmin kəmiyyətin müxtəlif müşahidələrdən toplanan qiymətlər toplusudur.

```
score = np.array([70, 85, 90, 85, 60])
score
```

Ədədi orta

Qiymətlərin cəmi onların sayına bölünür. Seçmənin mərkəzini bir ədədlə göstərir — lakin ucqar qiymət ortanı özünə tərəf çəkir, bu onun əsas zəif tərəfidir.

78

Orta qiymət

[70, 85, 90, 85, 60] seçməsi üçün

390

Cəm

5 müşahidənin cəmi

```
score = np.array([70, 85, 90, 85, 60])
score.mean()
np.mean(score)
```

Moda

Ən tez təkrarlanan qiymətdir. Seçmədə bir neçə belə qiymət ola bilər — bu halda çoxmodlu paylanma adlanır.

NumPy-də ayrıca moda funksiyası yoxdur. pandas sütununun **.mode()** metodu Series qaytarır — çünki nəticə birdən çox ola bilər.

```
score = pd.Series([70, 85, 90, 85, 60])
score.mode()
# Nəticə: 85 (iki dəfə təkrarlanır)
```

[70, 85, 90, 85, 60] seçməsində 85 iki dəfə görünür — moda odur.

Mediana

Sıralanmış seçmənin ortasındakı qiymətdir. Ucqar qiymət medianı ortaya çəkmir — bu onu ortadan üstün edir.

1

Sırala

[60, 70, 85, 85, 90]

2

Ortanı tap

Tək say → ortadakı element. Cüt say → iki ortanın ortalığı.

3

Nəticə

Mediana = **85**

```
score = np.array([70, 85, 90, 85, 60])
np.median(score) # → 85.0
```

Dispersiya

Qiymətlərin ortadan nə qədər yayıldığını ölçür. Hər fərqin kvadratı toplanır. Seçmə dispersiyasında cəm **n − 1**-ə bölünür — bu Besselin düzəlişidir.

1

Fərqi hesabla

Hər qiymətdən ortanı çıx: $x_i - \bar{x}$

2

Kvadrata al

$(x_i - \bar{x})^2$ — mənfi işarəni aradan qaldırır

3

n − 1-ə böl

ddof=1 seçmə dispersiyasını verir

```
score = np.array([70, 85, 90, 85, 60])
np.var(score, ddof=1) # ddof=0 yazsaq n-ə bölür
```

Standart kənarlaşma

Niyə vacibdir?

Dispersiyanın kvadrat köküdür. Ölçü vahidi ilkin kəmiyyətlə eyni qalır — buna görə nəticəni birbaşa şərh etmək mümkündür.

- Kiçik → qiymətlər ortaya yığılır
- Böyük → qiymətlər geniş yayılır

Kod nümunəsi

```
score = np.array([70, 85, 90, 85, 60])
np.std(score, ddof=1)
```

ddof dispersiyadakı ilə eyni götürülür. Seçmə üçün **ddof=1** düzgündür.

Bərabər paylanma

Verilmiş aralıqda hər qiymətin gəlmə şansı eynidir. Aralıqdan kənar qiymət gəlmir. **uniform(a, b)** bu aralıqdan seçmə götürür.

a

Aralığın alt həddi

b

Aralığın üst həddi

size

Seçmənin ölçüsü

```
rng = np.random.default_rng(0)
rng.uniform(0, 10, size=5)
# → [6.37, 2.69, 4.02, 0.77, 2.77]
```

Normal paylanma

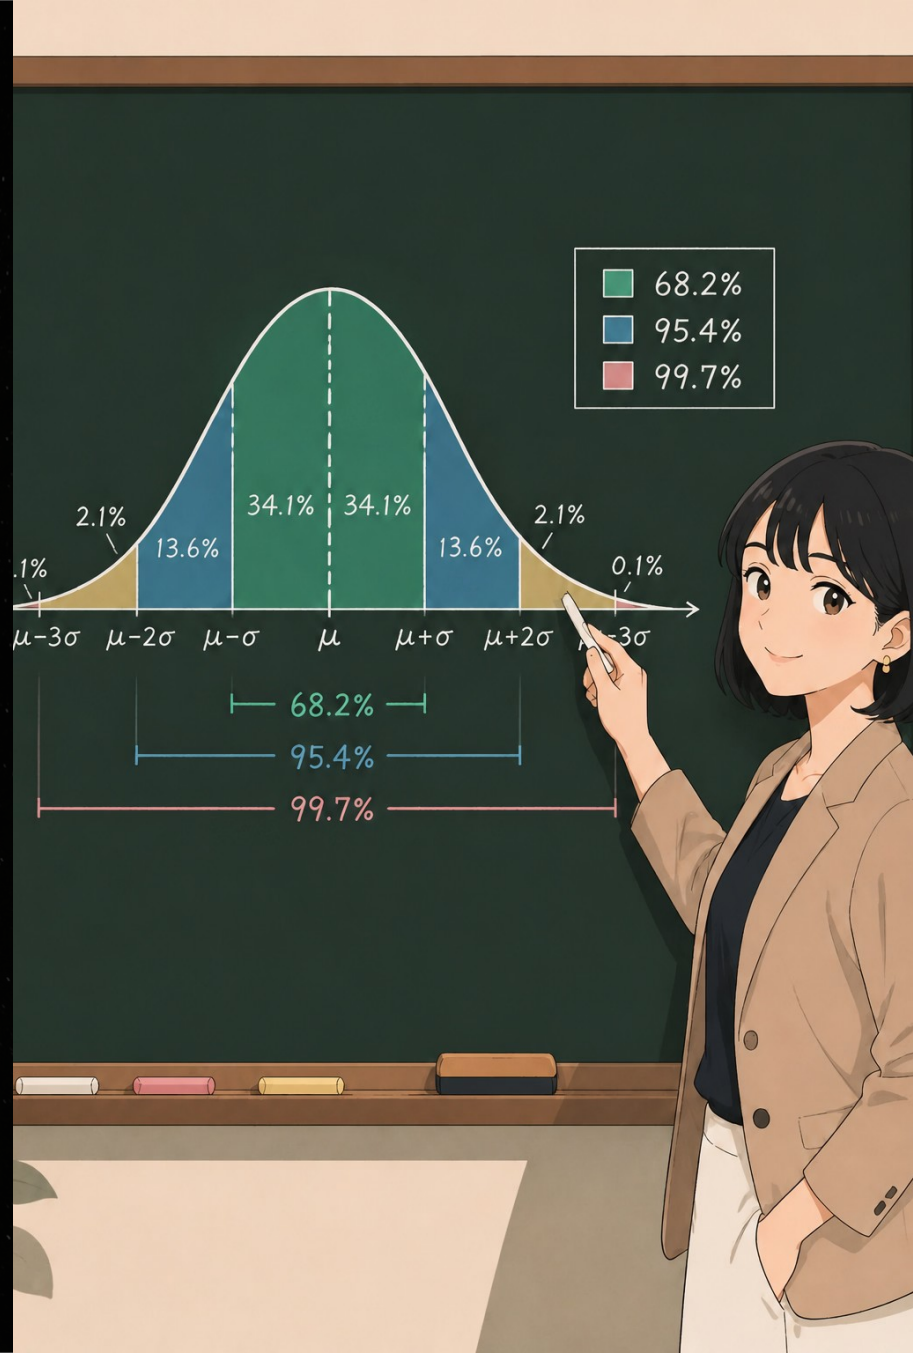
Kütlə mərkəz ətrafında zəng formasındadır. Çoxlu kiçik müstəqil təsirlərin cəmi tez-tez bu formaya düşür — buna görə statistikada ən çox istifadə edilən paylanmadır.

loc	scale
Paylanmanın mərkəzi (orta)	Standart kənarlaşma — yayılma

size

Nümunə sayı

```
rng = np.random.default_rng(0)
rng.normal(loc=78, scale=12, size=5)
```



Puasson paylanması

Müəyyən zaman ərzindəki hadisələrin **sayını** təsvir edir. Nəticə 0, 1, 2 və sonrakı tam ədədlərdir — mənfi ola bilməz.



lam (λ)

Orta hadisə sayıdır. Məsələn, bir saatda 3 müraciət.



Nəticə

Tam ədəd: 0, 1, 2, 3... Mənfi qiymət mümkün deyil.



Tətbiq sahəsi

Zəng sayı, veb trafik, nasazlıq sayı kimi hadisələr.

```
rng = np.random.default_rng(0)
rng.poisson(lam=3, size=8)
```

Kovariasiya və korrelyasiya

İki kəmiyyətin birlikdə necə dəyişdiyini ölçür. Korrelyasiya kovariasiyadan fərqli olaraq −1 ilə 1 arasına normallaşdırılır — ölçü vahidindən asılı deyil.

Müsbət korrelyasiya (+1-ə yaxın)

Hər ikisi birlikdə artır

Mənfi korrelyasiya (–1-ə yaxın)

Biri artanda digəri azalır

Sıfır ətrafında

Xətti əlaqə yoxdur

```
hours = np.array([2, 4, 5, 7, 9], dtype=float)
score = np.array([50, 65, 70, 85, 95], dtype=float)
np.cov(hours, score, ddof=1)
np.corrcoef(hours, score)
```

Matrisin diaqonalından kənar xana cütlüyün nəticəsidir.



matplotlib — Məlumatın şəkli

Fiqur, oxlar və qrafik. Histoqram, dairə, qutu, nöqtələr və sütunlar — məlumatı göz önünə gətirən vizuallaşdırma alətləri.

```
import matplotlib.pyplot as plt
```

Fiqur, oxlar və qrafik

Figure

Bütün şəkildir — ən xarici konteyner. Birdən çox Axes saxlaya bilər.

Axes

Figur üzərindəki bir koordinat sahəsidir. Qrafikin çəkildiyi yer buradır.

plt.subplots()

Figure və Axes-i birlikdə yaradır. Ən çox istifadə edilən başlanğıc metodudur.

```
fig, ax = plt.subplots()
ax.plot([1, 2, 3, 4], [70, 85, 90, 60])
ax.set_title("score")
plt.show()
```

Funksiyanın qrafiki

ax.plot nöqtələri xətlə birləşdirir. x eni sıx nöqtələrdən ibarət massivdir, y həmin nöqtələrdə funksiyanın qiymətidir. **np.linspace** bərabər aralıqlı nöqtələr yaradır.

linspace(-3, 3, 200)

−3-dən 3-ə 200 nöqtə

$y = x^2$

Hər nöqtənin funksiya qiyməti

```
x = np.linspace(-3, 3, 200)
y = x ** 2
fig, ax = plt.subplots()
ax.plot(x, y)
ax.set_xlabel("x")
ax.set_ylabel("y")
plt.show()
```

Histoqram

Qiymətləri intervallara bölür və hər intervalda neçə müşahidə olduğunu göstərir. Paylanmanın forması buradan oxunur — normal, bərabər, çarpaz.

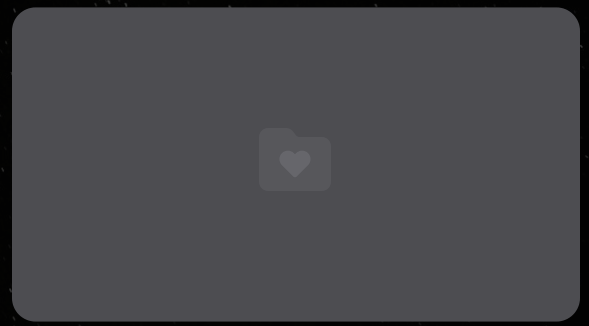
bins

İnterval sayıdır. Çox kiçik → qrafik "dişli" görünür. Çox böyük → ətraflı olur.

default_rng(0)

Toxum sabitləşdirir — eyni nəticəni yenidən alırsınız.

```
rng = np.random.default_rng(0)
sample = rng.normal(loc=78, scale=12, size=500)
fig, ax = plt.subplots()
ax.hist(sample, bins=20)
plt.show()
```



Dairəvi diaqram

Hissənin bütündəki payını göstərir. **autopct** faizi birbaşa dilimin üzərinə yazır — əlavə izaha ehtiyac qalmır.

```
labels = ["A", "B", "C"]
sizes  = [12, 7, 5]
fig, ax = plt.subplots()
ax.pie(sizes,
       labels=labels,
       autopct="%1.0f%%")
plt.show()
```

A — 50%

12 / 24 = 0.5

B — 29%

7 / 24 ≈ 0.29

C — 21%

5 / 24 ≈ 0.21

Box-plot (qutu diaqramı)

Kvartiləri, medianı və ucqar qiymətləri bir şəkildə göstərir. **describe** həmin kvartilləri ədədlə, box-plot isə vizual olaraq verir.

Qutu

Birinci kvartildən (Q1) üçüncü kvartilə (Q3) qədər — orta 50% burada yerləşir.

Ortadakı xətt

Mediandır — ucqar qiymətlər onu sürüşdürmür.

Bığlardan kənar

Ayrıca nöqtə kimi düşür — potensial ucqar qiymətlərdir.

```
score = [70, 85, 90, 85, 60, 100, 40]
fig, ax = plt.subplots()
ax.boxplot(score, tick_labels=["score"])
plt.show()
```

Nöqtəli diaqram (scatter)

Nə göstərir?

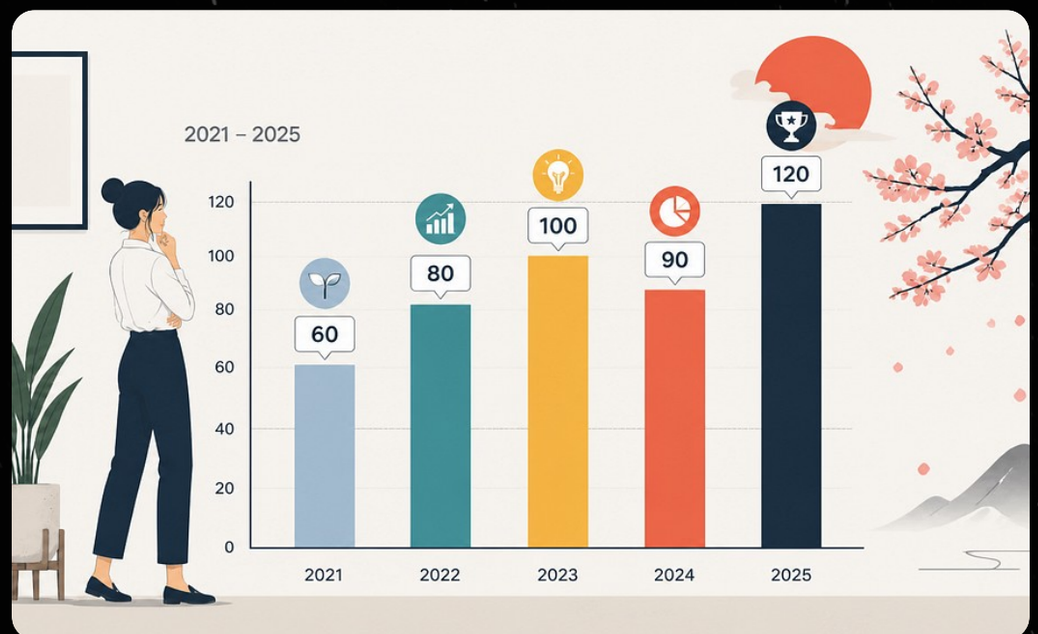
Hər nöqtə bir müşahidədir. Üfüqi ox bir kəmiyyət, şaquli ox isə o biridir. Korrelyasiyanın istiqaməti şəkildən dərhal oxunur.

- Nöqtələr yuxarı sola → müsbət
- Aşağı sola → mənfi
- Dağınıq → əlaqə yoxdur

```
hours = [2, 4, 5, 7, 9]
score = [50, 65, 70, 85, 95]
fig, ax = plt.subplots()
ax.scatter(hours, score)
ax.set_xlabel("hours")
ax.set_ylabel("score")
plt.show()
```

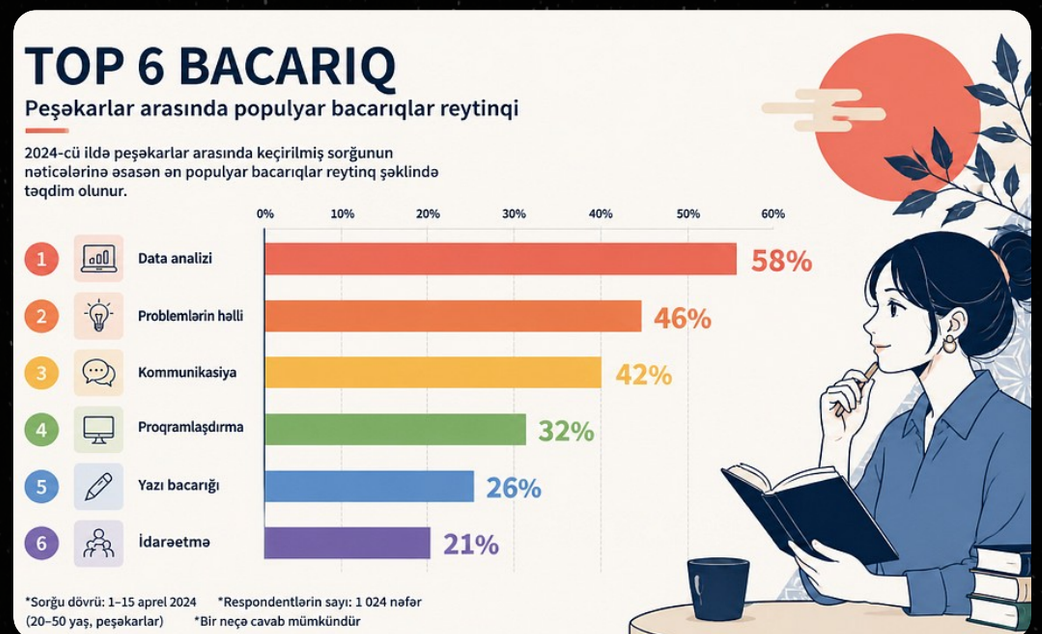
Sütun diaqramı (bar)

Hər sütun bir kateqoriyanın qiymətini göstərir. Hündürlük ədədi, adlar üfüqi oxda durur. Kateqoriyalar arasındakı fərqi müqayisə etmək üçün ən sadə alətdir.



ax.bar()

Şaquli sütunlar çəkir. names siyahısı etiketlər, score isə hündürlüklərdir.



ax.barh()

Üfüqi sütunlar üçün istifadə edilir. Uzun etiketlər olduqda daha oxunaqlıdır.

```
names = ["Aysel", "Murad", "Leyla", "Nigar"]
score = [70, 85, 90, 60]
fig, ax = plt.subplots()
ax.bar(names, score)
plt.show()
```